

تمرین کامپیوتری دوم درس مقدمه‌ای بر یادگیری ماشین - گروه ۲

نیمسال دوم ۱۴۰۴ - ۱۴۰۵

موعد تحویل: ۲۹ خرداد ۱۴۰۵

آداب انجام تمرینات کامپیوتری

- **همفکری** دانشجویان در انجام تمرینات مانعی ندارد ولی تمرینات باید به صورت مشخص توسط خود تحویل دهنده انجام گرفته باشد. در زمان تصحیح تمرینات شباهت تمرینات بررسی خواهد شد و تمرین‌های با شباهت غیرعادی مورد قبول نیست.
- استفاده از منابع اینترنتی برای گرفتن ایده‌ی حل سوالات مانعی ندارد ولی کپی کردن پاسخ تمرینات از هر منبعی مورد قبول نیست.
- استفاده از کتابخانه‌های آماده در صورتی که در صورت تمرین قید نشده باشد، مانعی ندارد.
- کدهای تحویل شده باید قابلیت اجرای دوباره را داشته باشند. در صورت وجود مشکل در زمان تصحیح (حتی به دلیل خطای تایپی)، قسمت‌های غیرقابل اجرا مورد قبول نیست. لطفاً قبل از تحویل تمرین حتماً کد خود را بررسی فرمایید.
- فایل ZIP شامل کدها و خروجی به همراه فایل گزارش (توضیحات در مورد آنچه انجام دادید و سوالات پرسیده شده) در CW آپلود گردد (در صورت استفاده از فرمت ipynb، می‌توانید توضیحات را در همان نوتبوک بنویسید و نیازی به گزارش نیست).
- سوالات و ابهامات در رابطه با این تمرین را می‌توانید در پیام‌رسان به [@mehrshaddddddd](mailto:mehrshaddddddd@smm236) و [@smm236](mailto:smm236) مطرح کنید.

سوال اول: طبقه‌بندی ستارگان

در نجوم، طبقه‌بندی ستارگان بر اساس ویژگی‌های طیفی آنها انجام می‌شود. طرح طبقه‌بندی که برای کهکشان‌ها، کوازارها و ستارگان استفاده می‌شود، یکی از بنیادی‌ترین طبقه‌بندی‌ها در علم نجوم است. فهرست‌بندی اولیه ستارگان و توزیع آنها در آسمان باعث درک این مسأله شد که آنها کهکشان خود ما را تشکیل می‌دهند و پس از تمایز کهکشان آندرومدا از کهکشان ما، با ساخت تلسکوپ‌های قوی‌تر، کهکشان‌های زیادی مورد مطالعه قرار گرفتند. این مجموعه داده به هدف طبقه‌بندی ستارگان، کهکشان‌ها و کوازارها بر اساس ویژگی‌های طیفی آنها طراحی شده است. این مجموعه داده متشکل از ۱۰۰ هزار مشاهده از فضااست که هر کدام توسط ۱۷ ویژگی و یک کلاس توصیف می‌شوند. کلاس هر مشاهده یک ستاره، کهکشان یا کوازار است.

ستون‌های موجود در مجموعه داده (فایل star.csv):

Columns:

1. 'obj_ID': Unique Object Identifier
2. 'alpha': Right Ascension Angle
3. 'delta': Declination Angle
4. 'u': Ultraviolet Filter
5. 'g': Green Filter
6. 'r': Red Filter
7. 'i': Near Infrared Filter
8. 'z': Infrared Filter
9. 'run_ID': Run Number used to identify the specific scan

10. 'rerun_ID': Rerun Number to specify how the image was processed'
11. 'cam_col': Camera column to identify the scanline within the run
12. 'field_ID': Field number to identify each field
13. 'spec_obj_ID': Unique ID used for optical spectroscopic (this means that 2 different observations with the same spec_obj_ID must share the same output class)
14. 'class': object class (galaxy, star or quasar object)
15. 'redshift': redshift value based on increase in wavelength
16. 'plate': Plate ID
17. 'MJD': Modified Julian Date
18. 'fiber_ID': Identifies the fiber that pointed the light at the focal plane in each observation

متغیر 'class' در واقع همان برچسب (label) ما می‌باشد که تعیین می‌کند جسم مورد نظر galaxy, star یا quasar است.

(۱,۱) داده‌ها را بخوانید و با دستور `info()` بررسی کنید کلاس‌ها را به صورت زیر به اعداد انکود کنید:

```
Galaxy: 0
Star: 1
Quasar: 2
```

(۲,۱) ماتریس همبستگی ویژگی‌های موجود در فایل را رسم کنید (می‌توانید از هیت‌مپ استفاده کنید). کدام ویژگی‌ها همبستگی بسیار کمی با class دارند؟ این ویژگی‌ها را حذف کنید.

(۳,۱) تعادل (balance) داده‌ها در کلاس‌های مختلف را بررسی کنید. آیا تعداد داده‌ها در کلاس‌های مختلف متعادل است؟ در صورتی که اینطور نیست، با استفاده از تکنیک‌های `under sampling`، تعداد دیتا در کلاس‌های مختلف را یکی کنید (می‌توانید از کتابخانه `imblearn` استفاده کنید).

نکته: در صورتی که تعداد داده‌ها برای سخت‌افزار شما زیاد است و یادگیری مدل‌ها زیاد از شما زمان گرفته است، می‌توانید از کوگل کولب استفاده کنید و یا اینکه با `under sampling` به صورت `balance` تعداد کل داده‌ها را به ۲۰ هزار داده برسانید.

(۴,۱) ویژگی‌ها را استاندارد کنید و سپس داده‌ها را ۲۰ درصد برای تست و ۸۰ درصد برای آموزش جدا کنید.

(۵,۱) می‌خواهیم با استفاده از SVM داده‌ها را طبقه‌بندی کنیم، با استفاده از کرنل خطی و مقادیر $0.1 - 1 - 10$ برای پارامتر C مدل را تعریف کنید و به ازای هر کدام از مقادیر C، مدل را ارزیابی کنید (ارزیابی را با رسم `confusion matrix`، محاسبه مقادیر `accuracy`، `Recall`، `F1-Score` و رسم نمودار ROC انجام دهید).

(۶,۱) حال با آموزش یک مدل `Logistic Regression`، داده‌ها را طبقه‌بندی کرده و مدل را ارزیابی کنید.

(۷,۱) در مدل `Logistic Regression` ضرایب بدست آمده در مدل و رابطه هر ویژگی با خروجی را بررسی کنید. کدام ویژگی‌ها مهم‌ترند و چرا؟

سوال دوم: تشخیص زودهنگام حمله قلبی

سازمان جهانی بهداشت برآورد کرده است که هر سال حدود ۱۲ میلیون مرگ در سراسر جهان به علت بیماری‌های قلبی رخ می‌دهد. نیمی از مرگ‌ومیرها در ایالات متحده و سایر کشورهای توسعه‌یافته به دلیل بیماری‌های قلبی-عروقی است. پیش‌بینی زودهنگام بیماری‌های قلبی-عروقی می‌تواند به تصمیم‌گیری در مورد تغییرات سبک زندگی در بیماران پرخطر کمک کند و در نتیجه عوارض ناشی از این بیماری‌ها را کاهش دهد. در این مجموعه داده، داده‌های مربوط به افراد آورده شده که ستون `Heart Attack Risk` مشخص می‌کند آیا ریسک حمله قلبی در این فرد وجود دارد یا خیر.

ستون‌های مجموعه داده (`heart_attack_risk.csv`):

```
Columns: ['Age', 'Sex', 'Cholesterol', 'Blood Pressure', 'Heart Rate', 'Diabetes', 'Family History', 'Smoking', 'Obesity', 'Alcohol Consumption', 'Exercise Hours Per Week', 'Diet', 'Previous Heart Problems', 'Medication Use', 'Stress Level', 'Sedentary Hours Per Day', 'Income', 'BMI', 'Triglycerides', 'Physical Activity Days Per Week', 'Sleep Hours Per Day', 'Continent', 'Hemisphere', 'Heart Attack Risk']
```

(۱,۲) با استفاده از دستور `info()` بررسی کنید آیا ستونی از داده‌ها، دارای خانه‌های خالی هستند یا خیر؟ در صورتی که خانه خالی‌ای وجود دارد، سطرهای متناسب با آن‌ها را حذف کنید.

۲,۲) ویژگی‌هایی که به صورت یک عدد نیستند را به طور مناسبی به اعدادی متناظر کنید. (راهنمایی: ستون Blood Pressure را به دو ستون تبدیل کنید و ستون‌هایی مثل Continent و Hemisphere را دیکود کنید).

۳,۲) داده‌ها را به صورت رندم ۸۰ درصد برای آموزش و ۲۰ درصد برای تست جداسازی کرده و داده‌ها را نرمالایز کنید.

۴,۲) این مجموعه داده‌ها را به کمک یک SVM با کرنل RBF طبقه‌بندی کرده و به ازای مقادیر مختلف پارامترهای C و gamma، صحت (accuracy) طبقه‌بندها را مقایسه کنید.

۵,۲) الگوریتم Perceptron را پیاده‌سازی کنید و با استفاده از آن داده‌ها را طبقه‌بندی کرده و مدل را ارزیابی کنید.

۶,۲) قسمت قبل را این بار با توابع آماده Perceptron انجام داده و نتایج مدل را با بخش قبل مقایسه کنید.

۷,۲) حال می‌خواهیم با استفاده از MLP داده‌ها را طبقه‌بندی کنیم. در رابطه با پارامترهای مختلف این مدل (تعداد لایه‌ها، نورون‌های پنهان، توابع فعالسازی و ...) تحقیق کرده و با استفاده از GridSearchCV، شبکه عصبی خود را تعریف کنید و مدل را ارزیابی کنید.

۸,۲) این بار یک مدل درخت تصمیم طراحی کنید. بهترین پارامترهای درخت را یافته و سپس با DecisionTreeClassifier و پارامترها، داده‌ها را طبقه‌بندی کرده و مدل را ارزیابی کنید.

۹,۲) تمامی مدل‌های استفاده شده در بخش‌های قبل را با یکدیگر مقایسه کنید. کدام مدل عملکرد بهتری داشته است؟ آیا استفاده از معیار صحت (accuracy) برای مقایسه مدل‌ها کافیست؟