
آداب انجام تمرینات کامپیوتری

- هدف اصلی تمرین کامپیوتری کسب مهارت در مباحث عملی حوزه یادگیری ماشین و آشنایی با ابزارهای موجود میباشد لذا همفکری دانشجویان در انجام تمرینات مانعی ندارد ولی تمرینات باید به صورت مشخص توسط خود تحویل دهنده انجام گرفته باشد و به تمام موارد پیاده سازی شده کاملاً مسلط باشد.
- در زمان تصحیح تمرینات شباهت تمرینات بررسی خواهد شد و تمرینهای با شباهت غیرعادی مورد قبول نیست.
- استفاده از منابع اینترنتی (سایت ها و ابزارهای مبتنی بر هوش مصنوعی) در این راستا برای گرفتن ایده‌ی حل سوالات مانعی ندارد ولی کپی کردن پاسخ تمرینات از هر منبعی مورد قبول نیست.
- استفاده از گنجخانه‌های آماده در صورتی که در صورت تمرین قید نشده باشد، مانعی ندارد.
- کدهای تحویل شده باید قابلیت اجرای دوباره را داشته باشند. در صورت وجود مشکل در زمان تصحیح حتی به دلیل خطای تایپی، قسمتهای غیرقابل اجرا مورد قبول نیست. لطفاً قبل از تحویل تمرین حتماً کد خود را بررسی فرمایید.
- فایل ZIP شامل کدهای تمرینات همراه گزارش (اگر در صورت تمرین نیاز به گزارش اعلام شده باشد) در CW آپلود گردد.

تمرین سری سوم	کاهش بعد و خوشه بندی	تاریخ تحویل	مطابق CW
---------------	----------------------	-------------	----------

نکات اجرایی مشترک برای همه بخش‌ها

برای اینکه نتایج قابل بررسی و قابل تکرار باشند، در ابتدای نوت‌بوک یک مقدار random seed تعریف کنید. این مقدار را به صورت زیر بسازید:

```
seed = 1000 + last_three_digits(student_id)
```

منظور از `last_three_digits(student_id)` سه رقم آخر شماره دانشجویی است. اگر شماره دانشجویی شما کمتر از سه رقم انتهایی قابل استفاده دارد، عدد را با صفر از سمت چپ کامل کنید. تمام انتخاب‌های تصادفی، از جمله انتخاب مراکز اولیه در K-Means و انتخاب نمونه آهنگ‌ها از خوشه‌ها، باید با همین `seed` انجام شوند. در هر سؤال، علاوه بر کد، حداقل یک سلول توضیحی کوتاه بنویسید و بیان کنید که خروجی به دست آمده چه معنایی دارد. نمودارهایی که رسم می‌کنید باید عنوان، نام محور افقی و نام محور عمودی داشته باشند. در صورت استفاده از توابع آماده مجاز، نام تابع و دلیل استفاده از آن را در یک جمله توضیح دهید.

۱ سؤال اول: خوشه‌بندی آهنگ‌های اسپاتیفای

در این سؤال، هدف بررسی این است که آیا می‌توان آهنگ‌های موجود در فایل `spotify.csv` را بر اساس ویژگی‌های عددی و محتوایی مرتبط، در چند گروه معنادار خوشه‌بندی کرد یا خیر.

۱.۱ خواندن داده و انتخاب ویژگی‌ها

داده را از فایل `spotify.csv` بارگذاری کنید. ابتدا شکل داده، نام ستون‌ها، نوع داده هر ستون و تعداد مقادیر گم‌شده را نمایش دهید. سپس ستون‌هایی را که برای خوشه‌بندی مناسب نمی‌دانید حذف کنید و تنها نام ترک و ویژگی‌هایی را نگه دارید که به نظر شما برای توصیف شباهت موسیقایی آهنگ‌ها مفید هستند. در یک سلول متنی، جدول کوتاهی شامل سه ستون بنویسید: نام ویژگی، نگه‌داشتن یا حذف کردن، و دلیل تصمیم. اگر از ویژگی‌های متنی یا دسته‌ای استفاده می‌کنید، در صورت نیاز می‌توانید از `LabelEncoder` در `sklearn.preprocessing` استفاده کنید؛ اما باید توضیح دهید که این تبدیل چه محدودیتی دارد.

۲.۱ استانداردسازی از ابتدا

یک کلاس یا تابع برای استانداردسازی داده‌ها با رفتار مشابه `StandardScaler` از ابتدا پیاده‌سازی کنید. استفاده مستقیم از `StandardScaler` برای این بخش مجاز نیست. تابع شما باید میانگین و انحراف معیار هر ویژگی را از داده محاسبه کند و سپس تبدیل زیر را اعمال کند:

$$z = \frac{x - \mu}{\sigma}$$

اگر انحراف معیار یک ویژگی صفر بود، باید در کد خود از تقسیم بر صفر جلوگیری کنید. پس از استانداردسازی، میانگین و انحراف معیار چند ستون نمونه را قبل و بعد از تبدیل نمایش دهید. سپس در یک پاراگراف توضیح دهید که چرا استانداردسازی پیش از PCA و K-Means اهمیت دارد.

۳.۱ کاهش بعد با PCA آماده

از پیاده‌سازی PCA در `sklearn` استفاده کنید و داده استاندارد شده را به فضای مؤلفه‌های اصلی ببرید. با استفاده از نسبت واریانس توضیح داده شده، تعداد مؤلفه‌های مناسب را انتخاب کنید. لازم است حداقل دو خروجی زیر را نمایش دهید:

(آ) نمودار واریانس توضیح داده شده تجمعی برحسب تعداد مؤلفه‌ها؛

(ب) عدد تعداد مؤلفه‌هایی که برای ادامه کار انتخاب کرده‌اید و دلیل انتخاب آن.

برای جلوگیری از انتخاب کاملاً سلیقه‌ای، یک آستانه مشخص برای واریانس تجمعی، مثلاً بین ۸۵ تا ۹۵ درصد، در نظر بگیرید و توضیح دهید چرا آن آستانه را انتخاب کرده‌اید.

۴.۱ پیاده‌سازی K-Means از ابتدا

الگوریتم K-Means را از ابتدا پیاده‌سازی کنید. استفاده از KMeans آماده در sklearn برای این بخش مجاز نیست. پیاده‌سازی شما باید حداقل شامل مراحل زیر باشد:

۱. مقداردهی اولیه مراکز خوشه‌ها با استفاده از seed تعریف شده؛

۲. تخصیص هر نمونه به نزدیک‌ترین مرکز بر اساس فاصله اقلیدسی؛

۳. به‌روزرسانی مراکز هر خوشه؛

۴. توقف بر اساس رسیدن به حداکثر تکرار یا تغییر بسیار کم مراکز؛

۵. ذخیره مقدار خطای درون خوشه‌ای در هر تکرار.

پس از اجرا، نمودار تغییر خطای درون خوشه‌ای برحسب شماره تکرار را برای یک مقدار نمونه از k رسم کنید و توضیح دهید آیا الگوریتم همگرا شده است یا خیر.

۵.۱ انتخاب تعداد خوشه‌ها

الگوریتم پیاده‌سازی شده خود را برای مقادیر k از ۳ تا ۱۰ اجرا کنید. برای هر مقدار k، دو معیار Silhouette Score و Davies-Bouldin Index را محاسبه کنید. سپس دو نمودار جداگانه رسم کنید:

آ) مقدار سیلوئت برحسب k؛

ب) مقدار شاخص Davies-Bouldin برحسب k.

با توجه به این دو معیار، مقدار مناسب k را انتخاب کنید. اگر دو معیار پاسخ متفاوتی دادند، باید در یک پاراگراف توضیح دهید که کدام معیار را ترجیح می‌دهید و چرا.

۶.۱ تحلیل خوشه‌ها و نمایش دوبعدی

برای مقدار k انتخاب شده، همه داده‌ها را با استفاده از دو مؤلفه اول PCA روی یک نمودار دوبعدی رسم کنید و رنگ هر نقطه را بر اساس شماره خوشه مشخص کنید.

سپس از هر خوشه، با استفاده از seed تعریف شده، دو آهنگ را به صورت تصادفی انتخاب کنید. برای هر خوشه، نام دو آهنگ انتخاب شده، فاصله آن‌ها در فضای ویژگی استاندارد شده یا فضای PCA و یک توضیح کوتاه درباره میزان نزدیکی آن‌ها بنویسید. اگر یک خوشه کمتر از دو عضو داشت، آن مورد را گزارش کنید و دلیل احتمالی آن را توضیح دهید.

در پایان این سؤال، در یک جمع‌بندی کوتاه بنویسید که آیا خوشه‌های به دست آمده از نظر شما قابل تفسیر هستند یا خیر. پاسخ شما باید به خروجی واقعی کد و نمودارها اشاره کند، نه فقط به تعریف تئوری خوشه‌بندی.

بخش اختیاری و امتیازی: Kernel PCA

با استفاده از Kernel PCA با کرنل گاوسی RBF، داده‌ها را به دو بعد کاهش دهید و نمودار پراکندگی آن را بر اساس خوشه‌های نهایی رسم کنید. سپس در چند جمله آن را با نمودار دوبعدی PCA معمولی مقایسه کنید. این بخش اختیاری است و امتیاز اضافه دارد.

۲ سؤال دوم: PCA، چهره‌های ویژه و طبقه‌بندی

این سؤال از دو قسمت تشکیل شده است. در قسمت اول، باید PCA را خودتان پیاده‌سازی کرده و روی داده IRIS اجرا کنید. در قسمت دوم، از PCA برای استخراج ویژگی از تصاویر چهره و سپس از LDA برای طبقه‌بندی استفاده می‌کنید.

۱۰۲ پیاده‌سازی PCA از ابتدا روی IRIS

تابع یا کلاس PCA خود را از ابتدا پیاده‌سازی کنید. استفاده از PCA آماده sklearn در این بخش مجاز نیست. پیاده‌سازی شما باید شامل مرکز کردن داده، محاسبه ماتریس کوواریانس، استخراج مقادیر ویژه و بردارهای ویژه، مرتب‌سازی مؤلفه‌ها و تصویر کردن داده روی مؤلفه‌های اصلی باشد. تابع خود را روی مجموعه داده IRIS اجرا کنید و داده را به دو بعد کاهش دهید. سپس نمودار دوبعدی داده‌ها را رسم کنید؛ رنگ نقاط باید بر اساس کلاس واقعی نمونه‌ها مشخص شود. در یک سلول متنی توضیح دهید که آیا دو مؤلفه اول برای جداسازی کلاس‌ها کافی به نظر می‌رسند یا خیر. برای اطمینان از صحت پیاده‌سازی، می‌توانید نتیجه خود را به صورت کیفی با خروجی PCA آماده sklearn مقایسه کنید، اما نمره این بخش بر اساس پیاده‌سازی خودتان خواهد بود.

۲۰۲ مفهوم چهره‌های ویژه

مفهوم eigenfaces یا چهره‌های ویژه را توضیح دهید و ارتباط آن را با PCA بیان کنید. توضیح شما باید به زبان خودتان باشد و به این نکته اشاره کند که هر تصویر چگونه به یک بردار تبدیل می‌شود، PCA چه الگوهایی را از مجموعه تصاویر یاد می‌گیرد و چرا این الگوها را می‌توان به صورت تصویر نمایش داد.

۳۰۲ خواندن مجموعه داده چهره‌ها و ساخت داده آموزش و آزمون

مجموعه داده چهره‌ها شامل ۴۰ پوشه است و در هر پوشه ۱۰ تصویر از یک فرد مشخص در حالت‌های مختلف وجود دارد. داده‌ها را بخوانید و برای هر فرد، پنج تصویر اول را برای آموزش و پنج تصویر آخر را برای آزمون استفاده کنید. سپس چهار آرایه زیر را بسازید:

```
train_X, test_X, train_y, test_y
```

برای خواندن تصاویر می‌توانید از کتابخانه opencv استفاده کنید. در صورت نیاز، آن را با دستور زیر نصب کنید:

```
pip install opencv-python
```

در خروجی این بخش، ابعاد ماتریس‌های آموزش و آزمون را چاپ کنید و توضیح دهید هر سطر و هر ستون در ماتریس داده چه معنایی دارد.

۴.۲ اجرای PCA روی تصاویر چهره

روی داده‌های آموزشی چهره، PCA را اعمال کنید و سپس داده‌های آموزش و آزمون را به فضای مؤلفه‌های اصلی منتقل کنید. تعداد مؤلفه‌ها را در یک محدوده مناسب، مثلاً بین ۴۰ تا ۵۰، انتخاب کنید و دلیل انتخاب خود را توضیح دهید. دقت کنید که PCA باید فقط روی داده آموزشی fit شود و سپس همان تبدیل روی داده آزمون اعمال شود.

حداقل پنج چهره ویژه اول را به شکل تصویر نمایش دهید و در یک جمله توضیح دهید که چرا این تصاویر شبیه چهره معمولی نیستند، اما همچنان الگوهای مهمی از تغییرات چهره‌ها را نشان می‌دهند.

۵.۲ آموزش طبقه‌بند LDA

یک طبقه‌بند LDA را روی داده‌های تبدیل شده با PCA آموزش دهید و دقت آن را روی داده آزمون گزارش کنید. علاوه بر دقت کلی، ماتریس درهم‌ریختگی را نیز نمایش دهید. در یک پاراگراف کوتاه توضیح دهید کدام افراد بیشتر با یکدیگر اشتباه شده‌اند و به نظر شما دلیل احتمالی آن چیست.

۶.۲ بررسی اثر تعداد مؤلفه‌های PCA

فرایند استخراج ویژگی با PCA و طبقه‌بندی با LDA را برای چند مقدار مختلف تعداد مؤلفه‌های PCA در بازه ۴۰ تا ۱۰۰ تکرار کنید. بهتر است حداقل از مقادیر زیر استفاده کنید:

۴۰, ۵۰, ۶۰, ۷۰, ۸۰, ۹۰, ۱۰۰

برای هر مقدار، دقت آزمون را ذخیره کنید و نمودار دقت برحسب تعداد مؤلفه‌ها را رسم کنید. سپس در یک جمع‌بندی توضیح دهید چه تعداد ویژگی برای این مجموعه داده کافی به نظر می‌رسد. پاسخ شما باید بر اساس روند نمودار و نتایج عددی باشد.

مواردی که باید در نوت‌بوک نهایی دیده شود

نوت‌بوک نهایی باید شامل موارد زیر باشد:

۱. اجرای کامل همه سلول‌ها بدون خطا؛
۲. توضیح دلیل انتخاب ویژگی‌ها در سؤال اسپاتیفای؛
۳. پیاده‌سازی استانداردسازی از ابتدا؛
۴. پیاده‌سازی K-Means از ابتدا؛
۵. نمودارهای معیارهای Silhouette و Davies-Bouldin؛
۶. انتخاب و تحلیل مقدار نهایی k ؛

۰۷. پیاده‌سازی PCA از ابتدا برای IRIS؛
۰۸. ساخت درست داده‌های آموزش و آزمون برای تصاویر چهره؛
۰۹. نمایش چند چهره ویژه؛
۰۱۰. آموزش LDA و تحلیل دقت؛
۰۱۱. بررسی اثر تعداد مؤلفه‌های PCA؛
۰۱۲. توضیح‌های کوتاه و اختصاصی بر اساس خروجی واقعی هر دانشجو.

نکته پایانی

تمرین‌هایی که فقط شامل خروجی‌های آماده، توضیح‌های کلی و نمودارهای بدون تحلیل باشند، کامل محسوب نمی‌شوند. هدف این تمرین، رسیدن به یک جواب عددی واحد نیست؛ بلکه توانایی پیاده‌سازی، تصمیم‌گیری، تحلیل خروجی و دفاع از مسیر حل اهمیت دارد.